

CUDA高级算子优化面试题（模拟面试版）

CUDA高级算子优化面试题（模拟面试版）

Q1：Kernel性能低，但occupancy、memory efficiency正常，如何定位？

答案：

不要直接怀疑CPU。先使用Nsight Systems确认CPU/GPU时间线、数据传输、kernel launch。

再使用Nsight Compute分析：

1. Memory Bound：看DRAM throughput、cache、memory latency。
2. Compute Bound：看SM throughput、指令吞吐、Tensor Core利用率。
3. Pipeline Bound：看Warp Stall Reason，例如Long Scoreboard、Barrier、Dependency。

Q2：为什么GPU需要大量Warp？

答案：

大量Warp用于Latency Hiding。

当一个Warp等待global memory时，SM可以切换执行其他ready Warp。

但如果计算资源已经饱和、memory bandwidth已经达到上限，增加Warp不能继续提升性能。

Q3：什么时候Shared Memory反而降低性能？

答案：

1. Shared Memory搬运和同步开销超过收益。
2. 使用过多Shared Memory导致Occupancy下降。
3. 出现Bank Conflict。
4. 原始Global Memory访问已经很好，额外引入Shared Memory没有收益。

Q4：LayerNorm为什么通常比GEMM难优化？

答案：

GEMM通常偏Compute Bound。

LayerNorm通常偏Memory Bound。

原因是计算量小，但是需要大量数据读写。

优化：

Kernel Fusion、Vectorized Load、Warp Reduction、减少Global Memory Traffic。

Q5：FlashAttention为什么快？

答案：

核心是减少HBM IO。

普通Attention需要保存中间Attention Matrix。

FlashAttention使用Tile计算，不保存完整矩阵，并使用Online Softmax保持数值稳定。

Q6：CUDA Kernel性能分析标准流程。

答案：

1. 保证正确性。
2. 建立baseline。
3. Benchmark。
4. Nsight Systems定位整体瓶颈。
5. Nsight Compute分析Kernel。
6. 判断Memory/Compute/Pipeline Bound。
7. 针对优化。
8. 再Benchmark验证。

Q7：GEMM多级Tiling。

答案：

Block Tiling：

利用Shared Memory提高Global Memory数据复用。

Warp Tiling：

划分Block内部计算任务。

Register Tiling：

一个Thread计算多个输出元素，提高Register级数据复用，减少Shared Memory访问。

Q8：既不是Memory Bound也不是Compute Bound怎么办？

答案：

分析Warp Stall Reason：

Long Scoreboard：等待数据。

Barrier：同步过多。

Dependency：指令依赖。

Not Selected：调度问题。

Q9：为什么Register Tiling提升性能？

答案：

让线程计算多个输出元素。

加载到Register的数据可以多次参与FMA。

代价是Register增加，可能降低Occupancy。

Q10：综合优化回答模板。

答案：

先定位问题，再判断瓶颈，再优化。

Memory：

Coalescing、Shared Memory、Fusion。

Compute：

Tensor Core、Vectorization、ILP。

Pipeline：

减少同步，提高并行。

优秀CUDA工程师不是直接改代码，而是通过Profiling找到真正瓶颈。